



UNIVERSIDAD
CATÓLICA
BOLIVIANA

INFORME – CASO DE ESTUDIO 1

ASIGNATURA MACHINE LEARNING

Grupo Nro. : 1

Integrantes:

- **Apaza Candia Brayan Joel**
- **Claros Suntura Juan Jose**
- **Maldonado Carvajal Alan Ariel**

Docente: Ing. Ovidio Roger

Carrera: Ingeniería en Sistemas

Fecha de entrega: 11/09/2026

Gestion: II/2026

La Paz - Bolivia

2026

Caso de estudio: Talent Retention – People Analytics

El informe presenta un proyecto de Machine Learning aplicado al área de Recursos Humanos mediante la metodología CRISP-DM. El propósito es utilizar datos históricos de empleados para apoyar dos necesidades de negocio: comprender los factores relacionados con el ingreso mensual y anticipar posibles fugas de talento.

El estudio utiliza el dataset IBM HR Analytics Employee Attrition & Performance, compuesto por 1.470 empleados y 35 variables originales. El trabajo aborda dos problemas supervisados: una regresión cuyo objetivo es MonthlyIncome y una clasificación binaria cuyo objetivo es Attrition, es decir, la posible salida de un empleado de la organización.

Metodología y alcance

CRISP-DM permite organizar el proyecto desde la comprensión del problema empresarial hasta la evaluación de los modelos. En este caso se completaron las fases de comprensión del negocio, comprensión de los datos, preparación de los datos, modelado y evaluación. La fase de despliegue no se realizó, porque el proyecto se encuentra en una etapa de desarrollo, modelado y evaluación.

Elemento	Descripción
Metodología	CRISP-DM, sin fase de despliegue
Sector	Recursos Humanos
Perspectiva	People Analytics
Regresión	Predicción de MonthlyIncome
Clasificación	Predicción de Attrition
Datos	1.470 registros y 35 variables

Resultados principales

- En los datos no se encontraron valores nulos.
- Attrition presenta un fuerte desbalance: 83,88% permaneció y 16,12% abandonó.
- JobLevel y MonthlyIncome presentan una correlación muy alta ($r = 0,9503$).
- La Regresión Lineal fue el mejor modelo para MonthlyIncome: MAE = 895,372; RMSE = 1.169,208; $R^2 = 0,937$.
- La Regresión Logística ajustada obtuvo ROC-AUC = 0,812 y PR-AUC = 0,589 en test.
- El umbral operativo seleccionado fue 0,55, considerando mayor costo para los falsos negativos.

1. Comprensión del negocio

El problema se plantea desde People Analytics: la organización busca contar con evidencia cuantitativa que permita analizar remuneraciones y anticipar posibles fugas de talento. El objetivo no es automatizar las decisiones de Recursos Humanos, sino proporcionar información para priorizar revisiones salariales y conversaciones de retención.

Objetivos de negocio

- Analizar los factores asociados al ingreso mensual y detectar diferencias importantes entre el salario real y el esperado.
- Identificar empleados con mayor probabilidad estimada de abandonar la organización.
- Reducir el riesgo de perder talento sin anticipación, priorizando Recall y PR-AUC en clasificación.
- Generar recomendaciones útiles para Compensación & Beneficios y responsables de gestión de personas.
- Mantener supervisión humana y criterios éticos, especialmente frente a variables demográficas sensibles.

Targets del proyecto

Tarea	Target	Pregunta de negocio
Regresión	MonthlyIncome	¿Qué factores explican el salario y qué empleados presentan desviaciones respecto a perfiles comparables?
Clasificación	Attrition	¿Qué empleados presentan mayor riesgo estimado de renunciar?

Costos de error

En la clasificación existe una diferencia importante entre los errores. Un falso positivo significa intervenir sobre una persona que probablemente no iba a renunciar, mientras que un falso negativo significa no detectar a una persona que finalmente abandona la empresa. El segundo error puede generar costos de reemplazo, onboarding y pérdida de conocimiento.

Resultado	Interpretación	Prioridad
Verdadero positivo	Se identifica correctamente una fuga potencial	Deseable
Verdadero negativo	Se identifica correctamente a quien permanece	Deseable
Falso positivo	Intervención preventiva innecesaria	Costo relativamente bajo
Falso negativo	Fuga no detectada	Costo alto

Por esta razón, Accuracy no se utiliza como criterio principal. Se priorizan Recall, Precision, ROC-AUC y especialmente PR-AUC. Para seleccionar el umbral se asumió un costo relativo de FN = 5 y FP = 1.

2. Comprensión de los datos

El dataset IBM HR Analytics Employee Attrition & Performance contiene 1.470 observaciones y 35 variables. Incluye información laboral y demográfica, con 26 variables numéricas y 9 categóricas. La revisión inicial mostró 0 valores nulos.

Característica	Resultado
Filas	1.470
Columnas originales	35
Variables numéricas	26
Variables categóricas	9
Valores nulos	0
Target de regresión	MonthlyIncome
Target de clasificación	Attrition

Calidad y distribución

Aunque no fue necesario imputar datos faltantes en este conjunto, el pipeline conserva una imputación defensiva: mediana para variables numéricas y moda para variables categóricas. Esto permite que el proceso sea más robusto ante futuros datos.

MonthlyIncome presenta una distribución sesgada hacia la derecha. La media es 6.502,93, la mediana 4.919 y el máximo 19.999. Esta diferencia refleja la presencia de empleados con niveles jerárquicos y remuneraciones considerablemente superiores.

Distribución de Attrition

De los 1.470 empleados, 1.233 no abandonaron la organización y 237 sí lo hicieron. Esto equivale a 83,88% de permanencia y 16,12% de fuga. El desbalance es relevante: un clasificador que siempre predijera No podría obtener aproximadamente 84% de Accuracy sin detectar ninguna fuga.

Correlaciones y relaciones relevantes

Se identificaron relaciones fuertes entre variables relacionadas con nivel, salario y experiencia. JobLevel y MonthlyIncome presentan $r = 0,9503$; JobLevel y TotalWorkingYears $r = 0,7822$; y MonthlyIncome y TotalWorkingYears $r = 0,7729$. Esta estructura es coherente con la lógica salarial de una organización.

En relación con Attrition, el análisis encontró una asociación importante entre OverTime = Yes y una mayor frecuencia de fuga. Esta señal se utiliza para interpretar el modelo, pero no se considera evidencia de causalidad.

3. Preparación de los datos

La preparación busca que el procesamiento sea reproducible y que la información del conjunto de prueba no influya indebidamente en el entrenamiento. Para ello se utilizaron pipelines de scikit-learn y se separaron las necesidades de regresión y clasificación.

Limpieza y selección

Se eliminaron cuatro columnas de las 35 originales: EmployeeNumber, EmployeeCount, StandardHours y Over18. EmployeeNumber es un identificador único, mientras que las otras tres variables son constantes en el conjunto. Después de esta limpieza quedaron 31 variables.

Variable	Tratamiento	Motivo
EmployeeNumber	Excluir	Identificador único
EmployeeCount	Excluir	Constante
StandardHours	Excluir	Constante
Over18	Excluir	Constante

Variables objetivo y features

Attrition se transformó en Attrition_flag, donde 1 representa fuga (Yes) y 0 representa permanencia (No), manteniéndose 237 casos positivos.

Tarea	Variables utilizadas	Target
Regresión	29 variables	MonthlyIncome
Clasificación	30 variables	Attrition_flag

Para clasificación se mantiene MonthlyIncome como predictor porque representa información disponible antes de la fuga. Para regresión se excluyen MonthlyIncome y Attrition para evitar utilizar el propio objetivo o el resultado de la otra tarea como predictor.

Codificación y división

Las variables categóricas nominales Department, EducationField, Gender, JobRole, MaritalStatus y OverTime se procesaron mediante One-Hot Encoding. BusinessTravel se trató como ordinal con el orden Non-Travel < Travel_Rarely < Travel_Frequently. Las variables numéricas se imputan por mediana y se estandarizan con StandardScaler.

Se utilizó una división 80/20. En clasificación se aplicó estratificación para conservar la proporción de fugas: 1.176 registros para entrenamiento y 294 para prueba. El preprocesador produjo 48 variables transformadas en entrenamiento.

Pipelines

ColumnTransformer y Pipeline encapsulan el preprocesamiento y el modelado. Las transformaciones se ajustan únicamente con los datos de entrenamiento dentro de cada proceso de validación, reduciendo el riesgo de data leakage.

4. Modelado y evaluación

Regresión de MonthlyIncome

Se comenzó con un baseline utilizando DummyRegressor con la estrategia de mediana. Su rendimiento fue MAE = 3.392,701, RMSE = 5.189,575 y $R^2 = -0,232$. Este resultado sirve como referencia mínima para comprobar si los modelos formales aportan una mejora.

Modelo	MAE	RMSE	R^2	Decisión
Regresión Lineal	895,372	1.169,208	0,937	Seleccionado
Ridge optimizado	896,385	1.171,329	0,937	Alternativa
Lasso optimizado	896,568	1.186,407	0,936	Alternativa
Baseline mediana	3.392,701	5.189,575	-0,232	Referencia

Debido a la colinealidad observada, también se evaluaron Ridge y Lasso mediante GridSearchCV con cinco particiones. El mejor alpha de Ridge fue 1,0 y el de Lasso 10,0. La Regresión Lineal fue seleccionada por presentar el menor RMSE en prueba. Su validación cruzada obtuvo RMSE medio de $1.148,40 \pm 73,38$.

Clasificación de Attrition

El baseline DummyClassifier, que siempre predice No, obtuvo Accuracy = 0,840, pero Recall = 0 para la clase de fuga. Esto demuestra que Accuracy puede ser engañosa cuando existe desbalance.

La Regresión Logística balanceada obtuvo inicialmente ROC-AUC = 0,802 y PR-AUC = 0,555. Luego se ajustó la regularización mediante StratifiedKFold y GridSearchCV, optimizando PR-AUC. El mejor valor de C fue 0,05.

Modelo	ROC-AUC test	PR-AUC test
Logística base	0,802	0,555
Logística ajustada	0,812	0,589

La validación cruzada del modelo ajustado produjo ROC-AUC = $0,833 \pm 0,031$ y PR-AUC = $0,635 \pm 0,053$. Por tanto, el modelo final supera claramente al baseline en la métrica especialmente importante para la clase minoritaria.

5. Evaluación, interpretación y recomendaciones

Umbral operativo

El proyecto no asume que 0,50 sea el umbral óptimo. Se evaluaron umbrales entre 0,05 y 0,95 usando costos relativos de FN = 5 y FP = 1. El menor costo observado correspondió a 0,55.

Métrica	Umbral 0,50	Umbral 0,55
Precision clase fuga	0,381	0,449
Recall clase fuga	0,681	0,660
F1 clase fuga	0,489	0,534
Falsos negativos	15	16
Falsos positivos	52	38
Costo relativo	127	118

Con 0,55 disminuyen los falsos positivos y el costo relativo total, aunque el Recall baja ligeramente. La matriz de confusión final es [[209, 38], [16, 31]]. La elección se fundamenta en el costo esperado y no únicamente en Accuracy.

Interpretación de resultados

En la regresión, las variables con mayor peso incluyen JobRole, JobLevel y TotalWorkingYears. Ridge reduce la magnitud de los coeficientes de variables colineales, mientras que Lasso puede llevar coeficientes a cero; en este caso, Lasso llevó 21 de 48 coeficientes a cero.

En clasificación, OverTime_Yes presenta un odds ratio aproximado de 1,829, mostrando una asociación positiva con la probabilidad estimada de fuga. También aparecen asociaciones positivas con BusinessTravel y determinados roles. Por otro lado, mayor satisfacción laboral, antigüedad y MonthlyIncome presentan asociaciones negativas.

Recomendaciones de negocio

- Revisar empleados cuyo salario real esté considerablemente por debajo del salario estimado para perfiles comparables.
- Usar el modelo salarial como herramienta de diagnóstico, no como determinante automático de aumentos.
- Revisar bandas salariales según nivel jerárquico, rol y antigüedad.
- Realizar auditorías periódicas por género, edad y estado civil para identificar posibles patrones de inequidad.
- Priorizar empleados con alta probabilidad estimada de Attrition utilizando el umbral 0,55.
- Revisar carga laboral y horas extra, por su asociación con fuga.
- Aplicar acciones de bienestar y satisfacción en segmentos de mayor riesgo.
- Registrar las intervenciones para evaluar posteriormente su efectividad.

Limitaciones y conclusión

El dataset corresponde a una fotografía histórica de una única organización, por lo que su generalización es limitada. Además, correlación no implica causalidad, los costos FN = 5 y FP = 1 son supuestos ilustrativos y la clase positiva es relativamente pequeña. Al no existir despliegue, todavía no se evaluaron drift, latencia ni comportamiento con nuevos datos.

En conclusión, CRISP-DM permitió estructurar el proyecto desde una necesidad de negocio hasta una evaluación cuantitativa. La Regresión Lineal presentó un desempeño sólido para MonthlyIncome, mientras que la Regresión Logística ajustada permitió identificar riesgo de Attrition con PR-AUC = 0,589 en test. Los resultados deben utilizarse como apoyo para decisiones humanas, acompañados de controles de equidad, validación con RRHH y seguimiento continuo.

Próximos pasos: validar las recomendaciones con RRHH y Finanzas, calibrar los costos con información real, enriquecer el dataset con encuestas de clima y entrevistas de salida, evaluar técnicas adicionales para el desbalance y monitorear el desempeño y drift cuando exista un escenario operativo.